Sistemi Operativi

Laurea in Ingegneria Informatica Università Roma Tre

Docente: Romolo Marotta

I/O e file management

- 1. Obiettivi ed organizzazione moduli di I/O
 - 1. I/O buffering
 - 2. I/O e Disk scheduling
- 2. Concetto di file e file system
 - 1. Operazioni su file e metodi di accesso
 - 2. Directory
 - 3. Allocazione
 - 4. Accenni di file system in Unix e Linux

1

I/O management

- Diversi tipi di dispositivi
 - Interazione con l'essere umano
 - Interazione con la macchina
 - Comunicazione tra macchine
- Caratteristiche differenti:
 - Applicazioni
 - Data rate
 - Controllo
 - Unità del trasferimento di dati
 - Rappresentazione del dato
 - Condizioni di errore
 - Gestione dei consumi

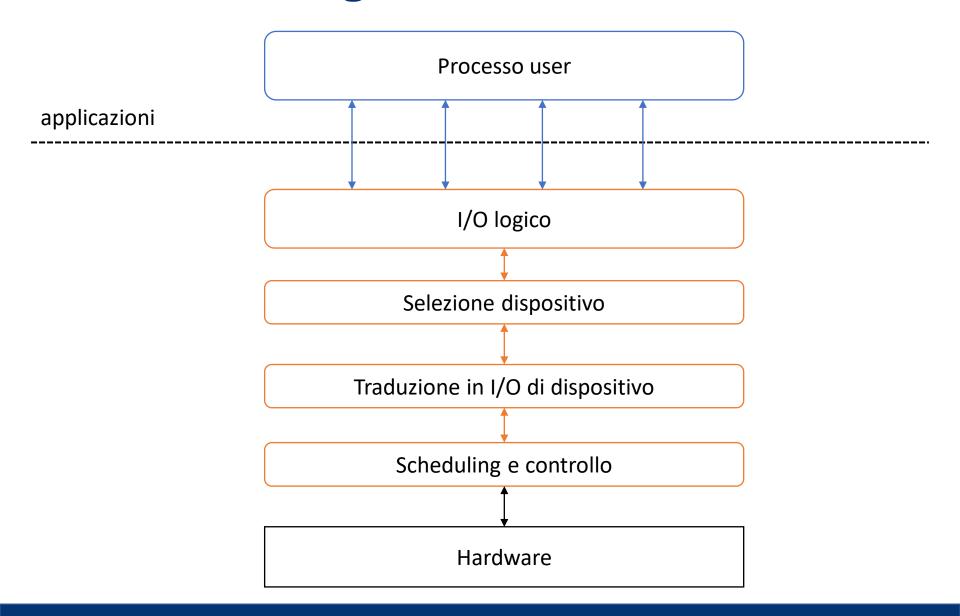
2

I/O management

Obiettivi:

- Efficienza
 - Tipicamente l'interazione con dispositivi di I/O è il collo di bottiglia
 - Multiprogrammazione allevia il problema, ma richiede swapping
 - Swapping richiede operazioni di I/O
- Generalità
 - Necessità di trattare i dispositivi in modo uniforme
 - Fornire servizi di I/O con interfacce standard (indipendenti dal tipo di dispositivo)
 - Progettazione gerarchica e modulare tesa a nascondere dettagli di basso livello

Modello di organizzazione moduli di I/O



I/O management

- Evoluzione delle funzioni di I/O
 - Programmed I/O
 - Processore attende la terminazione di comandi e copia dati da I/O a memoria
 - Interrupt-driven I/O
 - Processore non attende la terminazione di comandi e copia dati da I/O a memoria
 - Direct memory access
 - Processore non attende la terminazione di comandi e non copia dati da I/O a memoria

I/O buffering

L'I/O diretto su memoria dei processi ha implicazioni non banali:

- area destinata all'I/O non è swappabile
 - sottoutilizzo delle risorse
- area destinata all'I/O è swappabile
 - Deadlock
 - Processo bloccato in attesa di I/O e poi swappato
 - I/O in attesa che il processo sia riattivato
- I/O viene effettuato su memoria riservata al sistema operativo chiamato buffer
- L'utilizzo di buffer è in generale utile al fine di risolvere altre criticità:
 - Appianare la differenza di velocità tra produttore e il consumatore del dato
 - Appianare la differenza della taglia del dato che può essere maneggiata dal produttore e dal consumatore
 - Supportare la semantica di copia per l'I/O

I/O buffering

No buffering

User process I/O device Single buffer Operating system User process I/O device Double buffer Operating system User process ► I/O device Circular buffer Operating system User process I/O device

I/O scheduling

- Definisce la pianificazione per cui un dispositivo di I/O viene attivato per le sue operazioni
- In alcuni casi, mantenere l'ordine tra richieste di I/O e le effettive operazioni può essere necessario (e.g., terminale)
- FCFS non è necessariamente la soluzione più efficiente
 - Forte dipendenza dalle peculiarità dell'hardware caratteristico del dispositivo di I/O

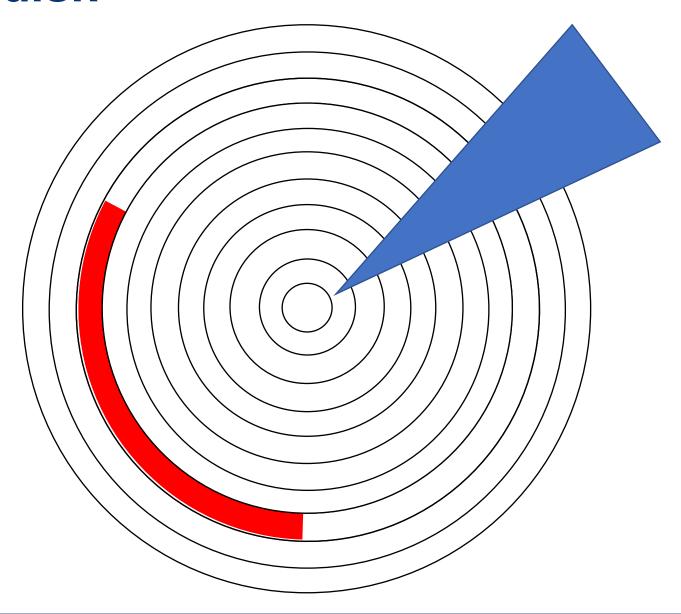
Hard disk – caratteristiche salienti

- Ogni blocco è accessibile in lettura/scrittura ad ogni istante di tempo
- L'usura del dispositivo è essenzialmente legata all'usura delle parti meccaniche coinvolte
 - Non ci sono relazioni dirette tra operazioni di scrittura/lettura ed usura del dispositivo
 - Relazioni indirette tra operazioni ed usura
 - Per leggere/scrivere è necessario muovere la testina

Tempo di accesso

- Tempo di accodamento della richiesta
- Tempo di acquisizione del canale di I/O (potrebbe essere condiviso con altri dispositivi)
- Seek time: tempo per spostare la testina sulla traccia corretta
- Ritardo di rotazione: tempo di rotazione per allineare l'inizio del settore di interesse alla testina
- Tempo di trasferimento: tempo speso a ruotare il disco affinché tutto il settore venga letto dalla testina

Hard disk



Hard disk – Tempi di accesso

- Tempo di trasferimento
 - B=byte da trasferire
 - N=byte per traccia
 - R=tempo di rivoluzione
 - BR/N
- Ritardo di rotazione
 - in media occorre metà giro per posizionarsi sul settore corretto
 - Tipicamente il disco gira ad una velocità costante (da 5400rpm a 15000rpm)
 - Da 5.5ms a 2ms
- Seek time
 - in media occorre un terzo del full seek time (dalla traccia più interna a quella più esterna)
 - tipicamente nell'ordine dei millisecondi

Hard disk - Tempi di accesso

Ritardo di rotazione

- Perché metà giro è la distanza attesa per allinearsi al settore di interesse?
- Una volta che la testina raggiunge la traccia di interesse, l'inizio del settore può trovarsi ad una qualsiasi distanza angolare dalla testina
- In altre parole, la distanza angolare X è uniformemente distribuita tra 0 e l'angolo giro (2π)
 - $X \sim f(x) = \frac{1}{2\pi} \operatorname{per} x \in [0, 2\pi], 0 \operatorname{per} x \notin [0, 2\pi]$

•
$$\mathbb{E}(X) = \int_{-\infty}^{+\infty} x f(x) \, dx = \int_{0}^{2\pi} \frac{x}{2\pi} \, dx = \left[\frac{x^2}{4\pi}\right]_{0}^{2\pi} = \frac{4\pi^2}{4\pi} = \pi$$

Hard disk - Tempi di accesso

Seek time

- Perché un terzo del full seek time è la distanza attesa per raggiungere la traccia di interesse?
- Si calcola come il rapporto tra la somma di tutte le distanze possibili tra due tracce (A) e il numero di movimenti distinti che la testina può effettuare (B)
- Sia N il numero di tracce del disco
- La traccia di partenza può essere scelta tra N
- La traccia destinazione può essere scelta tra N
- $B = N^2$

Hard disk - Tempi di accesso

• Data la traccia i, il numero di tracce D(i,j) da attraversare per raggiungere una traccia j è

$$D(i,j) = |i - j|$$

 La somma di tutte le possibili distanze tra una specifica traccia i e una generica traccia j è

$$A_i = \sum_{j=1}^{N} D(i,j) = \sum_{j=1}^{N} |i-j|$$

La somma di tutte le possibile distanze A è

$$A = \sum_{i=1}^{N} A_i = \sum_{i=1}^{N} \sum_{j=1}^{N} |i - j|$$

$$\sum_{i=1}^{N} \left[\sum_{j=1}^{i} (i-j) + \sum_{j=i+1}^{N} (j-i) \right]$$

Hard disk – Tempi di accesso

Seek time

$$\sum_{i=1}^{N} \left[\sum_{j=1}^{i} (i-j) + \sum_{j=i+1}^{N} (j-i) \right]$$

$$\sum_{i=1}^{N} \left[\sum_{j=1}^{i} (i-j) + \sum_{j=1}^{N} (j-i) - \sum_{j=1}^{i} (j-i) \right]$$

$$\sum_{i=1}^{N} \left[\sum_{j=1}^{i} 2(i-j) + \sum_{j=1}^{N} (j-i) \right]$$

$$\sum_{i=1}^{N} \left[2i^{2} - i(i+1) + \frac{N(N+1)}{2} - Ni \right]$$

$$\sum_{i=1}^{N} \left[i^{2} - i + \frac{N(N+1)}{2} - Ni \right]$$

$$\frac{N(N+1)(2N+1)}{6} - \frac{N(N+1)}{2} + \frac{N^{2}(N+1)}{2} - \frac{N^{2}(N+1)}{2}$$

$$\frac{2N^{3} + 3N^{2} + N}{6} - \frac{N(N+1)}{2}$$

$$\frac{N^{3}}{3} - \frac{N}{12}$$

Hard disk – Tempi di accesso

Seek time

- Perché un terzo del full seek time è la distanza attesa per raggiungere la traccia di interesse?
- Il seek time atteso è

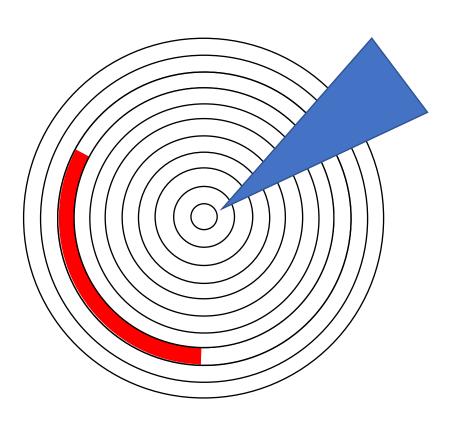
$$\frac{A}{B} = \frac{\frac{N^3}{3}}{N^2} = \frac{N}{3}$$

Hard disk – Accesso sequenziale

- Esempio
 - 500 settori per traccia
 - Average seek time = 4ms
 - Velocità di rotazione = 15000rpm = 250rps
 - Seek time per tracce adiacenti trascurabile
- Dati posizionati su 5 tracce consecutive
 - Tempo di rivoluzione = 4ms
 - Tempo di trasferimento = 5x(tempo di rivoluzione) = 20ms
 - Tempo di seek = 4ms (da considerare una sola volta)
 - Ritardo di rotazione complessivo = 5x(tempo di rivoluzione)/2 = 10ms
 - Tempo totale per l'accesso = 20ms + 10ms + 4ms = 34ms

Hard disk - accesso casuale

- Esempio
 - 500 settori per traccia
 - Average seek time = 4ms
 - Velocità di rotazione = 15000rpm = 250rps
 - Seek time per tracce adiacenti trascurabile
- Dati posizionati su 2500 settori non consecutivi
 - Tempo di rivoluzione = 4ms
 - Tempo di trasferimento = 5x(tempo di rivoluzione) = 20ms
 - Tempo totale di seek = 2500x(tempo di seek) = 10s
 - Ritardo di rotazione complessivo = 2500x(tempo di rivoluzione)/2 = 5s
 - Tempo totale per l'accesso = 20ms + 10s + 5s = 15.02s



 Minimizzare i movimenti meccanici è un aspetto cruciale per massimizzare le performance di accesso a disco

Seek time è oggetto di numerosi algoritmi di

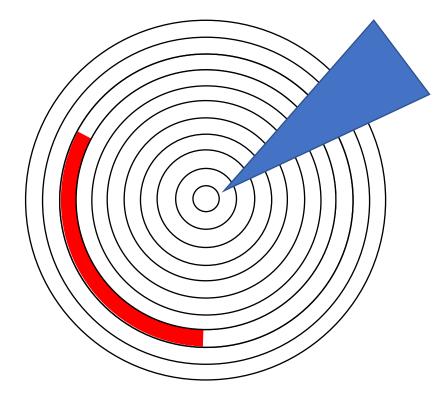
ottimizzazione

Metodologia

 Esecuzione sintetizzata come una sequenza di richieste identificate dal numero di traccia

Metrica

 numero di tracce complessivamente attraversate



 Minimizzare i movimenti meccanici è un aspetto cruciale per massimizzare le performance di accesso a disco

Seek time è oggetto di numerosi algoritmi di

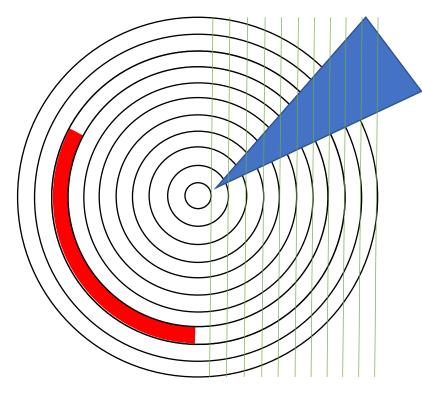
ottimizzazione

Metodologia

 Esecuzione sintetizzata come una sequenza di richieste identificate dal numero di traccia

Metrica

 numero di tracce complessivamente attraversate



 Minimizzare i movimenti meccanici è un aspetto cruciale per massimizzare le performance di accesso a disco

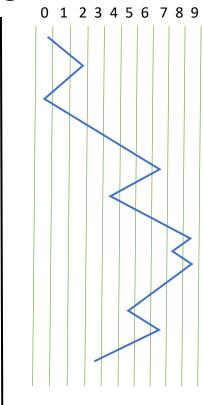
Seek time è oggetto di numerosi algoritmi di

ottimizzazione

Metodologia

 Esecuzione sintetizzata come una sequenza di richieste identificate dal numero di traccia

- Metrica
 - numero di tracce complessivamente attraversate

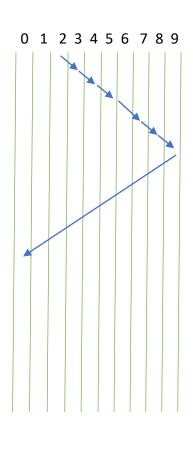


tempo

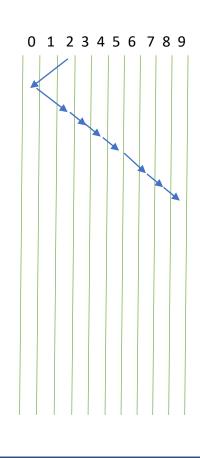
- Richieste:
 - 0,2,0,7,4,9,8,9,5,7,3
 - Posizione iniziale: 2
- FCFS
 - Richieste servite nell'ordine di arrivo
 - No starvation
 - Non minimizza seek time
 - Movimenti totali della testina: 32

tempo

- Richieste:
 - 0,2,0,7,4,9,8,9,5,7,3
 - Posizione iniziale: 2
- Shortest-seek-time-first (SSTF)
 - Seleziona la traccia successiva che minimizza il seek time
 - 2,3,4,5,7,7,8,9,9,0,0
 - Movimenti totali della testina: 16
 - Starvation
 - Non minimizza seek time



- Richieste:
 - 0,2,0,7,4,9,8,9,5,7,3
 - Posizione iniziale: 2, direzione decrescente
- SCAN (elevator)
 - Il seek avviene in una data direzione fino a che non ci sono più richieste lungo quella direzione
 - 0,0,2,3,4,5,7,7,8,9,9
 - Movimenti totali della testina: 11
 - Performance simili a SSTF
 - Sfavorisce tracce servite in precedenza
 - Favorisce tracce agli estremi
 - Starvation



tempo

- SCAN (elevator)
 - Sfavorisce tracce servite in precedenza
 - Favorisce tracce agli estremi
 - Starvation

CSCAN

- Le richieste vengono soddisfatte in un'unica direzione
- Starvation

FSCAN

- Due code per la gestione delle richieste
- Una coda viene usata per lo scheduling secondo SCAN
- Nuove richieste vengono inserite in una coda di richieste pendenti
- Quando la coda di scheduling corrente è vuota, le due code vengono scambiate

- Gli algoritmi mostrati si focalizzano sul seek time
- Nei dischi moderni
 - il seek time è comparabile con il tempo di rotazione
 - non mostrano la posizione fisica del dato
- I produttori implementano algoritmi di scheduling nel controller del disco tesi a minimizzare sia seek time che ritardi di rotazione
- Il sistema operativo può delegare al controller se l'unico obiettivo è la performance
- Tuttavia, esistono scenari in cui alcune richieste sono prioritarie rispetto ad altre

Solid state drives

- Basati su tecnologia flash
- Le scritture deteriorano le celle flash
 - Erase
 - Program
 - Una cella flash può supportare un numero limitato di cicli Program/Erase
- La tecnologia NAND:
 - notevole densità (byte per chip)
 - Asimmetria tra unità di erase (blocco=N pagine) e program (pagina)
- Le pagine vengono gestite dal controller all'interno dell'unità SSD al fine di garantire wear leveling
 - I dati vengono spostati al fine di controllare operazioni di erase
- Nascondono al sistema operativo la posizione fisica dei dati
- I sistemi operativi:
 - Spesso adottano politiche di scheduling semplici (FCFS)
 - Devono notificare la cancellazione dei dati

Operazioni di I/O logico

- Necessità di astrarre dalle peculiarità del dispositivo
- Si basano su modelli di riferimento
 - Stream I/O
 - Block I/O
- Le interfacce (system call) esistono in relazione ad oggetti logici
- Per interagire con un oggetto è necessario aprire un canale di I/O
- Il sistema operativo mantiene informazioni di sessione che permettono di relazionare operazioni susseguenti sull'oggetto
- Il trasferimento di dati da/verso oggetti logico può riflettersi su attività che coinvolgono dispositivi hardware (e.g., disco o interfacce di rete)

File system

Concetto di file

- File: minima unità informativa archiviabile
- Il ciclo di vita di un file è scorrelato dal ciclo di vita del processo che lo ha creato
- Se il file è archiviato su un dispositivo di memoria non volatile (e.g., disco, ssd), allora il ciclo di vita del file può includere molteplici riavvii della macchina
- Un file è costituito da un insieme di record
- Un record è l'unità minima manipolabile da un'applicazione all'interno di un file

File system

- Il file system è il modulo di sistema operativo per gestire file
- Associa ad un file una serie di attributi:
 - Nome
 - Timestamp (creazione, modifica)
 - Protezione (chi può accedervi e con quali modalità)
- Gli attributi (in parte) sono memorizzati in un Record di Sistema disgiunto dal file

Operazioni su file

Creazione

Allocazione del record di sistema e inizializzazione del file

Eliminazione

 Deallocazione del record di sistema e rilascio di tutti i record allocati per il file di interesse

Apertura

 Inizializzazione di una sessione e di un relativo indice per accessi al file nella sessione

Chiusura

Distruzione della sessione, dei suoi metadati e dell'indice

Scrittura/Lettura

Accesso a partire dal record a cui l'indice fa riferimento

Riposizionamento (seek)

Aggiornamento dell'indice

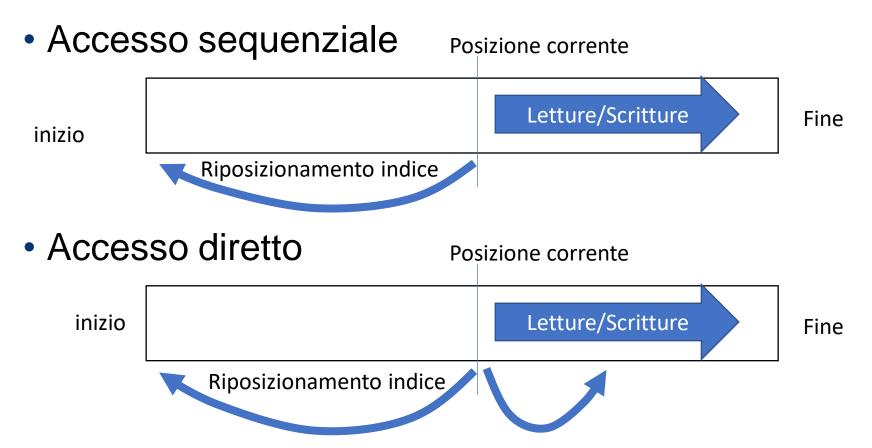
Troncamento

Distruzione di record del file

Indice di accesso

- Anche chiamato file pointer
- È un concetto di sessione
 - Non fa parte del record di sistema
- Una sessione può essere condivisa tra processi
 - Non è incluso nell'immagine di processo
- È memorizzato in una immagine di sessione
 - Struttura dati utilizzata per memorizzare tutti i metadati necessari alla gestione di accessi nell'ambito della sessione
- La modalità di aggiornamento dell'indice dipende dalle modalità di accesso ai record supportati dal file system

Metodi di accesso

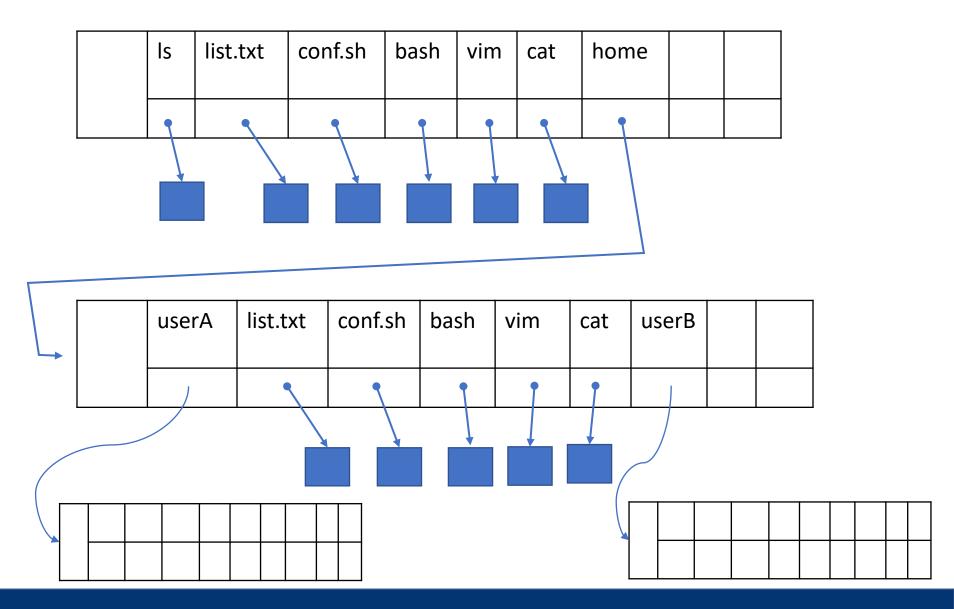


- Accesso indicizzato
 - Grazie all'accesso diretto è possibile costruire indici per individuare specifici blocchi identificati da una chiave di ricerca all'interno del file

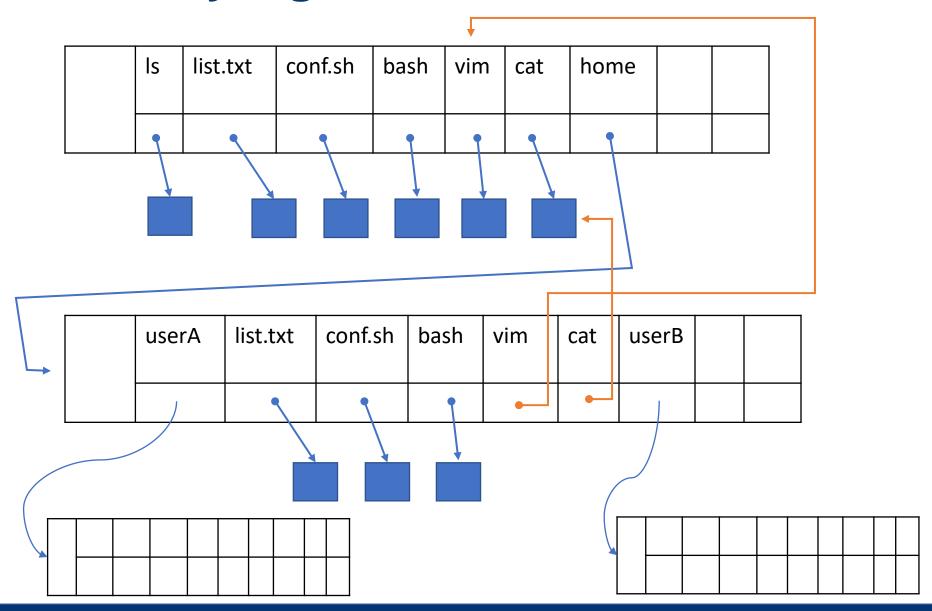
Directory

- Data un'area in cui è possibile archiviare file, il relativo file system si preoccupa di
 - Gestire l'area
 - Gestire i file in essa contenuti
- Nell'area di archivio esistono:
 - File
 - Record di Sistema
- Come ottenere l'elenco dei file archiviati in una determinata area?
 - Scansione di tutta l'area di archivio ed individuazione dei record di sistema (inefficiente)
 - Utilizzare un apposito record/file, chiamato directory, in cui memorizzare:
 - Nome del file
 - Relativo Record di sistema

- Data una directory, questa può contenere un solo file con un dato nome
 - Pros: semplice
 - Cons: nessuna libertà nel raggruppare e/o nominare file
- Il problema può essere risolto con una rappresentazione gerarchica delle directory
 - Albero di directory
- Una directory mantiene l'associazione tra:
 - Nome e Record di sistema (quindi file)
 - Nome e sottodirectory



- Directory ad albero (tree-structured directory):
 - Offrono flessibilità nell'organizzare i file
 - Non possono supportare condivisione fisica di file
- Directory a grafo aciclico
 - Un Record di sistema può esser referenziato (direttamente o indirettamente) a partire da più directory



- Directory ad albero (tree-structured directory):
 - Offrono flessibilità nell'organizzare i file
 - Non possono supportare condivisione fisica di file
- Directory a grafo aciclico
 - Un Record di sistema può essere referenziato (direttamente o indirettamente) a partire da più directory
 - Una directory può essere referenziata da più directory
 - Reference count
- Directory a grafo
 - Navigazione del grafo non banale (necessario identificare cicli)
 - Garbage collection al fine di individuare file/directory non raggiungibili

Accesso e protezione

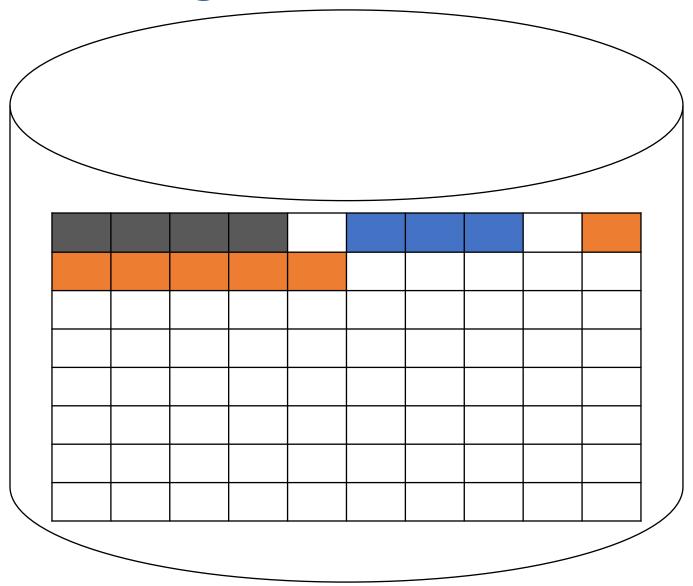
- A file e directory sono associate informazioni di protezione
 - Quali tipi di accesso sono consentiti:
 - Scrittura
 - Lettura
 - Esecuzione
 - Per quali utenti:
 - Proprietario
 - Gruppo
 - Altri
- Access control list
 - Lista di coppie <utente,permessi> per uno specifico file

Allocazione su storage

- Tipicamente l'unità di lettura/scrittura su memorie di massa è orientata al blocco (N byte)
- Come allocare i blocchi in un dispositivo per ospitare un file la cui taglia richiede più blocchi?
 - Allocazione contigua
 - Allocazione a catena (linked allocation)
 - Allocazione a indice

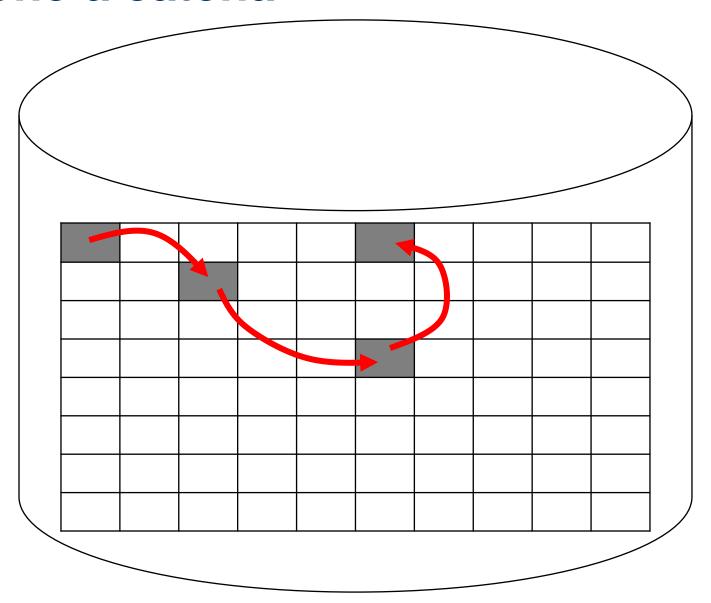
Allocazione contigua

Record di sistema FileA 0,4 FileB 5,3 FileC 9,6



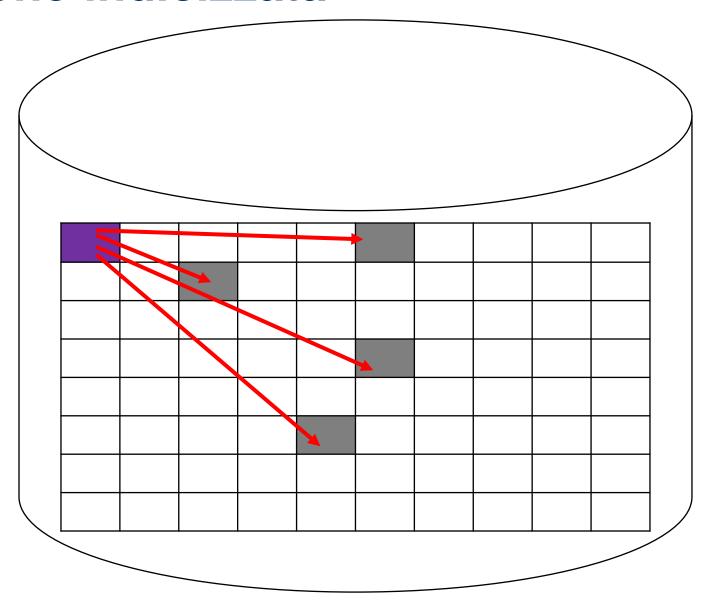
Allocazione a catena

Record di sistema FileA 0



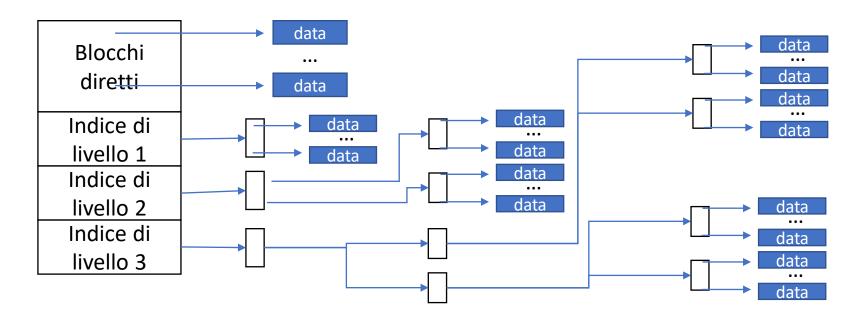
Allocazione indicizzata

Record di sistema FileA 0



File system UNIX

- Un file è uno stream di byte (taglia di un record pari ad 1 byte)
- Accesso diretto
- Record di sistema chiamato inode
- Allocazione indicizzata a livelli multipli



Attributi UNIX

- Tipo di file:
 - -: file regolare
 - d : directory
 - I: link simbolico
 - b : block device
 - c : char device
- Identificatore utente e gruppo proprietari
- Permessi di accesso
 - r (4) lettura
 - w(2) scrittura
 - x(1) esecuzione
- Attributi "speciali"
 - Specifica di identificazione dinamica
 - SUID
 - SGID
 - Sticky bit (solo per directory)
 - Rimuove la possibilità di cancellare file all'interno della directory di cui non si è owner

Servizi per accesso a File

- int open(char *file_name, int option_flags [, int mode])
 - invoca la creazione/apertura di un file
 - Argomenti
 - *file_name: puntatore alla stringa di caratteri che definisce il nome del file da aprire
 - 2. option_flags: specifica la modalita' di apertura (read, write etc.)
 - 3. mode (opzionale): specifica i permessi per owner, group, others in caso di creazione contestuale ad apertura
 - Restituzione
 - -1 in caso di fallimento,
 - un descrittore per l'accesso al file
- int close(int descriptor)
 - invoca la chiusura di un file tramite descrittore
 - Restituzione -1 in caso di fallimento

Servizi per accesso a File

- O_RDONLY: apertura del file in sola lettura;
- O_WRONLY: apertura del file in sola scrittura;
- O_RDWR: apertura in lettura e scrittura;
- O_APPEND: apertura del file con puntatore alla fine del file; ogni scrittura sul file sarà effettuata a partire dalla fine del file;
- O_CREAT : crea il file con modalità d'accesso specificate da mode sole se esso stesso non esiste;
- O_TRUNC : elimina il contenuto del file se esso gia' esistente.
- O_EXCL: (exclusive) serve a garantire che il file sia stato effettivamente creato dalla chiamata corrente.

Servizi per accesso a File

- ssize_t read(int descriptor, char *buffer, size_t size)
- ssize_t write(int descriptor, char *buffer, size_t size)
- off_t lseek(int fildes, off_t offset, int whence);
 - SEEK_SET
 - SEEK_CUR
 - SEEK_END

File descriptor

- Alcuni descrittori particolari:
 - 0: standard input
 - 1: standard output
 - 2: standard error
 - Associati a specifici dispositivi di I/O
- I descrittori vengono ereditati da processi creati tramite fork
- Duplicazione di descrittori
 - int dup(int descriptor)
 - int dup2(int oldfd, int newfd)

Altri servizi di gestione

• Link:

- hard: int link(const char *oldpath, const char * newpath)
- soft: int symlink(const char *oldpath, const char *newpath)

Directory:

- int mkdir(const char *pathname,mode_t mode)
- int rmdir(const char *pathname)

Permessi

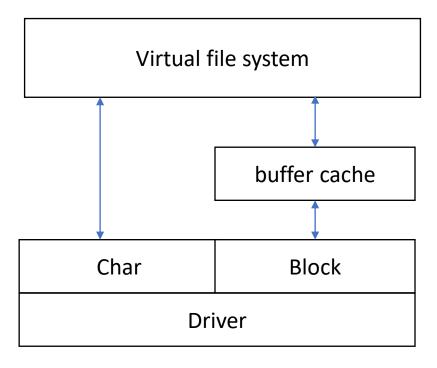
- int chmod(const char *path, mode_t mode);
- int fchmod(int fildes, mode_t mode);

Proprietà

- int chown(const char *pathname, uid_t owner, gid_t group);
- int fchown(int fd, uid_t owner, gid_t group);

I/O in sistemi UNIX

- I dispositivi sono gestiti come file
- Inode possono essere associati a dispositivi
- Le effettive operazioni dipendono dall'entità associata all'inode



Altri servizi offerti da file system

File locking

- utile per limitare il numero di processi concorrenti che possono manipolare il file
- Diversi approcci
 - mandatory (Windows)
 - advisory (UNIX via fcntl)

Gestione di errori

- Controlli di consistenza
 - Rileva eventuali problematiche (e.g., non allineamenti tra metadati e directory)
 - Alcune inconsistenze potrebbero essere irreparabili
- Journaling
 - creazione di log delle attività su file system (transazioni)
 - all'occorrenza replay/abort delle transazioni

In-memory file system (Linux)

ramdisk

- creazione di un dispositivo a blocchi sintetico, su cui è installato un file system noto
- spreco di memoria e cpu-clock
 - e.g., ai dispositivi a blocchi viene associata una RAM cache

ramfs

- File system che sfrutta il meccanismo di RAM cache verso il disco
- I blocchi in cache non vengono mai riportati su disco
- I blocchi sono sempre marcati come dirty per evitarne il replacement da algoritmi di VM
- · La memoria dedicata non è swappabile
- Non è possibile specificare una taglia massima

tmpfs

 come ramfs ma swappabile ed è possibile specificare taglia massima

File management in C - Esempio 1

```
#include <stdio.h>
#include <fcntl.h>
#include <stdlib.h>
#include <unistd.h>
#define BUFSIZE 250
#define abort(msg) do{printf(msg);exit(1);}while(0)
int main(int argc, char *argv[]) {
    int ifd, ofd, size r, size w, written = 0, end = 0;
    char buffer[BUFSIZE];
    /* check parameters */
    if (argc != 3) abort("usage: copy <source> <target>\n");
    /* open the input file and check errors */
    ifd=open(argv[1],O RDONLY);
    if (ifd == -1) abort("input open error\n");
```

File management in C - Esempio 1

```
/* opend output file and check errors */
ofd=open(argv[2],O WRONLY|O CREAT|O TRUNC,0660);
if (ofd == -1) abort("output creation error\n");
while(!end){
    /* read up to BUFSIZE from input file and check errors */
    size r=read(ifd,buffer,BUFSIZE);
    if (size r == -1) abort("read error\n");
    /* has EOF been reached? */
    end = size r == 0;
    /* write BUFSIZE to destination file */
    size w = write(ofd,buffer,size r);
    if (size w == -1) abort("write error\n");
    printf("written: %d\n", size w);
/* close file descriptors */
close (ifd);
close (ofd);
```

File management in C - Esempio 2

```
#include <stdio.h>
#include <stdlib.h>
#include <fcntl.h>
#include <unistd.h>
#define FILE NAME "log.txt"
#define STDOUT 1
#define abort (msg) do{printf(msg); exit(1);} while(0)
int main() {
    int ofd;
    /* opend output file and check errors */
    ofd=open(FILE NAME, O WRONLY | O CREAT | O TRUNC, 0660);
    if (ofd == -1) abort("output creation error\n");
    close(STDOUT); /* close standard output */
    ofd = dup(ofd); /* duplicate file descriptor */
    if (ofd == -1) abort("dup failed\n");
    execlp("ls","ls",NULL); /* run 'ls' */
```